

垂直Paxos和主备复制

Leslie Lamport、Dahlia Malkhi 和 Lidong Zhou 微
软研究院
dalia@microsoft.com、lidongz@microsoft.com

类别和主题描述符

C.2.4 [Computer Systems Organization]: 计算机通信网络分布式系统

一般条款

可靠性、算法、理论

一、简介

基于容易发生故障的商品组件构建的大规模分布式存储系统越来越受欢迎。在这些大型系统中，故障很常见，而复制通常是数据可靠性的解决方案。众所周知的共识算法和实际系统中的实际复制协议之间仍然存在明显的差距：诸如Paxos之类的共识算法主要用于维护全局配置信息，而不是用于实际的数据复制。

这种差距并非偶然；定义经典共识算法的抽象模型并不能完全满足真实分布式系统的需求。在经典的共识问题中，有一个由一组固定的 n 进程组成的单个 *replica group*，其中最多 f 个进程可能会失败。实际上，分布式系统由大量重叠的副本组组成，每个副本组负责维护系统数据的子集。每个特定副本组仅部署少量服务器（通常是 $f + 1$ ，少量 f ）。当副本发生故障时，会立即用新副本替换它们（这一过程称为 *re-configuration*），然后再出现其他故障会导致数据永久丢失。整个系统拥有丰富的服务器，方便重新配置和新的副本部署。

我们通过称为 Vertical Paxos [1] 的算法系列中的两个新算法弥补了这一差距，该算法源自 Paxos 共识算法。Vertical Paxos 允许使用来自 *auxiliary configuration master* 的重新配置指令在单个共识决策中更改配置。配置主机可以使用普通 Paxos 的复制状态机方法来实现。在实践中，这样的主节点很自然地可以维护系统中许多副本组的配置。主服务器仅在重新配置时被调用，这种情况应该不频繁，因此单个主服务器可以为许多单独的副本组提供服务。

我们的治疗与 *primary*-特别相关

Copyright is held by the author/owner(s).
PODC'09, August 10–12, 2009, Calgary, Alberta, Canada.
ACM 978-1-60558-396-9/09/08.

backup 方法。实际分布式系统中常见的经典主备复制协议仅使用 $f + 1$ 服务器来容忍 f 故障。为了绕过解决共识问题所需的 $2f + 1$ 进程的下限，主备份协议必须使用外部服务（例如我们的配置主机），或者对故障做出更具限制性的假设。据我们所知，以前还没有基于外部服务的主备份协议具有严格的正确性证明。我们的两种 Vertical Paxos 算法产生了两种可证明正确的主备份协议。一是严格制定现有协议。第二个是在实践中有用的新变体。

2.从Paxos到垂直Paxos

与普通 Paxos 一样，Vertical Paxos 通过执行一系列逻辑上独立的共识算法实例来实现复制状态机，实例 i 选择 i^{th} 状态机命令。使用显式索引很容易区分不同实例的动作，但由于异步，可能会在时间上交错。

有四个角色：*clients* 提交要添加到完全有序的命令序列中的命令。*Learners* 实现状态机：它们了解在每个实例中选择什么命令并按顺序执行命令。*Leaders* 和 *acceptors* 执行协议以达成共识决策。某些接受者集合称为 *quorums*；任何两个法定人数都有非空交集。接受者集合及其法定人数结构称为共识的 *configuration*。客户端向任何活跃的领导者发送请求。一个进程可以扮演多个角色。

为了容错，当前一个领导者未能及时取得进展时，必须激活新的领导者。与普通 Paxos 一样，共识实例的执行可能包含多个领导者激活，每个激活都试图达成决策。领导者激活被称为（由于历史原因）*ballots*；每张选票都有一个唯一的编号。复制的状态机执行将 *horizontally* 作为共识实例序列进行，而 *vertically* 将随着选票数量的增加而进行。

共识算法的核心是由领导者用新选票执行的协议。与普通 Paxos 一样，新领导者必须发现在所有情况下是否有任何命令是在较低编号的选票中选出的。与此同时，新领导人必须阻止数量较少的选票选择任何进一步的命令。然后，在前任领导者提出命令但可能未被选择的任何情况下，领导者都会尝试确保命令的选择。对于没有提出命令的情况，它

可以提出新的建议。如果法定人数的接受者在这次投票中确认了该命令，则在投票中选择该命令。稍后投票的领导者可以类似地查询过去提出的命令，并通过联系法定数量的接受者来阻止新的命令。在标准 Paxos 中，新选票的领导者执行以下操作。

Phase 1: 领导者与接受者进行一轮消息交换。当它收到法定数量的接受者的回复时，它会在每个实例中了解到（i）可能已选择的命令 c ，或（ii）没有选择任何命令。在这次交换中，领导者还获得了接受者的承诺，即不再响应编号较低的选票中的任何进一步提案（在异步系统中可以随时到达）。

Phase 2: 对于情况（i）成立的每个实例，领导者都会向接受者提出命令 c 。对于情况（ii）成立的情况，它会在从客户端收到新命令时提出新命令。

接受者接受、存储并确认领导者的提案，除非更高编号选票的领导者指示他们忽略该选票。

Vertical Paxos 通过两种方式概括了传统的 Paxos 算法。首先，Vertical Paxos 允许不同的配置与每个选票相关联。一个单独的辅助配置主机决定并维护从选票号到相应配置的映射。因此，重新配置是在选票号码上“垂直”进行的。

第二个概括是，它将 *read* 仲裁与接受器的 *write* 仲裁区分开来，其中任何写入仲裁都与任何其他仲裁相交；协议的第一阶段涉及读取仲裁，而第二阶段涉及写入仲裁。这种概括相当简单，但当选票的配置发生变化时就变得尤其重要。特别是，主备复制使用读和写仲裁不同的配置，并在发生故障时重新配置。

在 Vertical Paxos 中，配置主机启动新的投票，选择其编号、领导者和配置。Vertical Paxos 的两个阶段工作如下。在第一阶段，领导者不仅与新选票配置中的已读取法定人数进行通信，而且还与较低编号选票配置中的已读取法定人数进行通信。因此，它可以了解在编号较低的选票中选择的任何命令，同时防止在这些选票中选择任何新命令。

Vertical Paxos 的第二阶段与标准 Paxos 相同，只是领导者在当前选票的配置中接触写入法定人数。

当存储在其接受器上的所有可能选择的命令对于更高编号的选票的接受器来说是已知的时，旧的配置就变得过时了，并且不再联系它的读取法定人数。这是通过 *state transfer* 过程发生的，其中领导者读取存储在较低编号选票的读取法定人数上的命令，并将可能选择的命令写入新选票中的写入法定人数。Vertical Paxos 算法的两个变体在状态转移方面的配置被视为 *active* 时有所不同。

Vertical Paxos II 确保任何时候都有一个活动配置。新的领导者发起从当前活动配置到新配置的状态转移，只有在状态转移完成后，它才会请求主节点激活新配置。

Vertical Paxos II 领导者协议改编自 Paxos 领导者协议，如下所示。在第一阶段，领导者联系当前活跃投票中的接受者的法定人数。第二阶段分为几个阶段。

- A:** 对于领导者学习可能已选择的命令 c 的每个实例，领导者都会在第二阶段向写入法定人数的接受者提议 c 。
- B:** 当所有这些实例的第二阶段完成时，领导者要求主控激活新的选票号（和新的配置）。
- C:** 对于其他情况（没有选择命令），领导者等待来自客户端的下一个建议命令，并在协议的第 2 阶段提出值。

在 Vertical Paxos I 中，master 立即激活新配置。配置保持活动状态，直到主节点从领导者那里得知配置的状态已转移给更高编号选票的接受者。该算法允许多个配置同时处于活动状态。开始新的选票后，主节点会通知新选票的领导者哪些配置处于活动状态。读者可以参考 [1] 了解两种 Vertical Paxos 协议的完整描述。

3. 垂直 Paxos 和主备

Vertical Paxos 最有趣的情况是任何单个接受器形成读取法定人数，而唯一的写入法定人数是所有接受器的集合。这样的配置允许仅使用 $f + 1$ 个接受器进行 f 容错。此外，我们可以使领导者成为接受者之一，并在重新配置时从当前接受者中选择新的领导者。新的领导者本身就是前一次投票的法定人数，并且它可以自行执行第一阶段。这意味着，在 Vertical Paxos II 中，唯一需要的状态转移是在领导者和任何新接受者之间。以领导者为 *primary*，所有其他接受者为 *backups*，我们获得了传统的主备系统。

大多数主备份协议都维护单个活动配置，如 Vertical Paxos I 捕获的那样，它需要在重新配置之前进行状态转移。在实际系统中，状态传输往往涉及复制大量数据，因此成本高昂。通过允许多个活动配置，Vertical Paxos I 将状态传输与重新配置解耦。当状态从旧配置转移时，可以激活新配置来接受新请求。

4. 参考资料

[1] 莱斯利·兰波特、达丽娅·马尔基和周立东。垂直 Paxos 和主备复制。技术报告 MSR-TR-2009-63, Microsoft, 2009 年 5 月。